

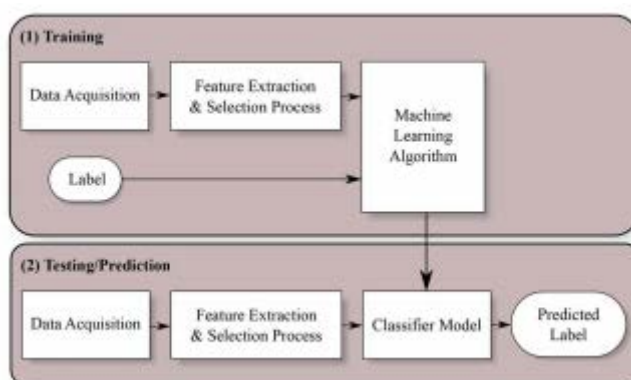
<b>Tytuł:</b>	Physical activity recognition from smartphone accelerometer data for user context awareness sensing
<b>Autorzy:</b>	Johan Wannenbourg, Reza Malekian
<b>Data publikacji:</b>	12 grudnia 2017
<b>Źródło:</b>	<a href="http://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&amp;arnumber=7476869&amp;tag=1">http://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&amp;arnumber=7476869&amp;tag=1</a>

Autorzy publikacji wskazują na użyteczność rozpoznawania aktywności w opiece zdrowia. W ogólności, do rozpoznawania aktywności wykorzystują dane zebrane za pomocą smartfonu przy użyciu akcelerometru. Zaś do analizy danych algorytmy uczenia maszynowego. Przeanalizowano różne algorytmy w celu znalezienia takiego, który ma najlepszą skuteczność rozpoznawania wszystkich aktywności oraz takich, które najlepiej wypadają dla określonej aktywności. Cały proces przetwarzania zbieranych sygnałów odbywa się na zdalnym serwerze.

### 1. Proces analizy

Autorzy podzielili proces rozpoznawania aktywności na następujące etapy:

- 1) Wstępne przetwarzanie danych
- 2) Ekstrakcja cech sygnałów
- 3) Trenowanie modelu
- 4) Klasyfikacja



Rysunek 1 Schemat blokowy postępowania podczas klasyfikacji sygnałów z użyciem algorytmów uczenia maszynowego z nadzorem

### 2. Zbieranie sygnałów

- **Smartfon:** z systemem Android
- **Lokalizacja smartfonu:** w kieszeni spodni przy biodrach
- **Czujnik:** 3-osiowy akcelerometr
- **Częstotliwość próbkowania:** 10 Hz (ponieważ autorzy zauważyli, że częstotliwość zmian sygnałów aktywności jest mniejsza niż 5 Hz, stąd zastosowali kryterium Nyquista, mówiącym o tym, że częstotliwość próbkowania powinna być co najmniej dwa razy większa od częstotliwości podstawowej).

### 3. Analizowane aktywności

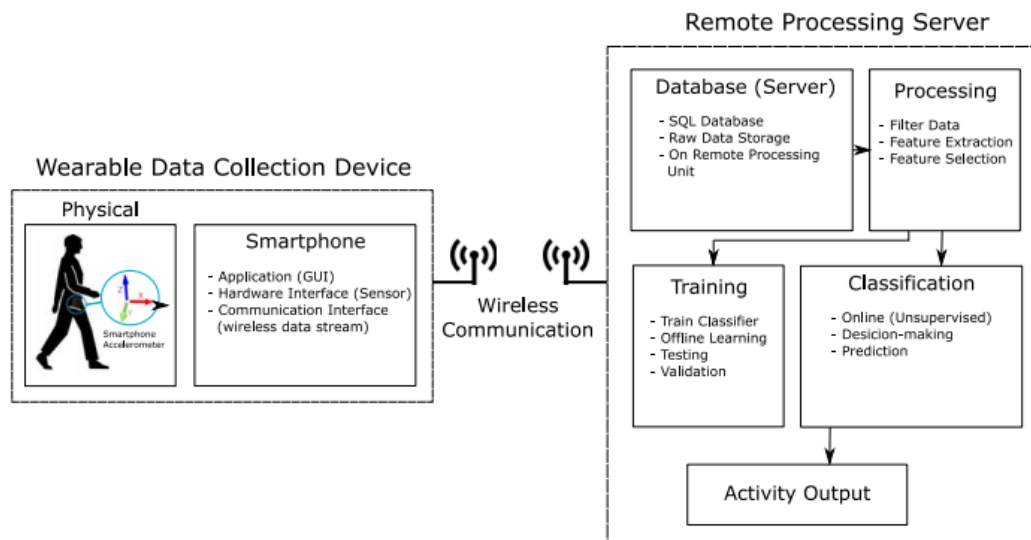
- Statyczne
  - Stanie
  - Siedzenie

- Leżenie
- Dynamiczne
  - Chodzenie
  - Jogging

#### 4. Przegląd przebiegu eksperymentu

Układ zbierania danych i przetwarzania podzielono na dwie części:

- 1) Noszony przyrząd (smartfon) do zbierania danych – akwizycja surowych danych oraz bezprzewodowa komunikacja z serwerem (przez Wi-Fi).
- 2) Zdalna jednostka (serwer) przetwarzająca otrzymane dane oraz dokonująca klasyfikacji (zebrane dane są gromadzone w bazie danych – służą one do trenowania oraz testowania modelu).



Rysunek 2 Schemat blokowy postępowania w eksperymencie

#### 5. Przetwarzanie sygnałów

- 1) Wstępne przetwarzanie:

Po akwizycji danych połączono ze sobą sygnały tej samej aktywności tworząc duży zbiór próbek, który miał posłużyć do trenowania i testowania modelu. Zbiory łączono w losowej kolejności, by zredukować obciążenie modelu.

Kolejnym krokiem było znormalizowanie danych do 1, co pozwala na jednakowe „potraktowanie” danych od różnych aktywności przez model, tym samym zmniejszając obciążenie oraz wariancję. Znormalizowane dane zostały dalej podzielone na dane treningowe oraz testowe w stosunku 70%/30%. Od tej chwili wszystkie operacje przetwarzania były przeprowadzone zarówno na danych treningowych oraz testowych.

Następny etap, jakiemu zostały poddane surowe dane, to okienkowanie (windowing), co polega na systematycznym przesuwaniu „ślizgającego” okienka po zbiorze danych. Istotną kwestią jest rozmiar okna – według różnych badań powinien zawierać przynajmniej jeden cykl aktywności by jednoznacznie móc ją zidentyfikować. W publikacji zdecydowano się na 1-sekundowe okno. Okno stosuje się do wyizolowania grupy próbek na cele ekstrakcji cech sygnału – stąd zastosowano tu okno prostokątne.

Okno powinno być też nakładające (overlapping), co pozwala na płynną analizę danych, a nie tylko określonych segmentów sygnałów. Ustalono, że 50-procentowy overlapping jest optymalny do wyboru cech (przy częstotliwości próbkowania 10 Hz, 1-sekundowe okno składa się z 10 próbek, a połowa z tego będzie nowymi próbkami w każdym oknie).

## 2) Ekstrakcja cech

W sumie zebrano 46 cech (przedstawiono w tabeli 1.), z których następnie utworzono wektor cech.

Tabela 1 Przegląd wybranych cech sygnałów

W dziedzinie czasu	W dziedzinie częstotliwości
Średnia	średnia
Maksimum	Maksimum
Minimum	Minimum
Mediana	Skośność
Odchylenie standardowe	Kurtoza
Odchylenie od średniej	Analiza głównych składowych
Rozstęp ćwiartkowy	
Pierwiastek średniokwadratowy	
Analiza głównych składowych	

Ekstrakcja cech sygnałów jest kluczowym etapem podczas rozpoznawania aktywności człowieka, zważywszy na to, iż to one determinują dokładność rozpoznawania. W zależności od aktywności poszczególne cechy wpływają w różnym stopniu na skuteczność rozpoznania.

## 3) Wybór cech

W specjalnym narzędziu obliczeniowym WEKA każdy element wektora został przeanalizowany pod kątem statystycznym, dając informację, jaki każdy z nich ma wkład na rozpoznawanie aktywności („czy są to dobre cechy”). Zastosowano tzw. *InfoGainAttributeEval* w programie WEKA, gdzie atrybuty są oceniane i rankingowane w odniesieniu do ich udziału w rozpoznawaniu aktywności. Po przefiltrowaniu wektora zdecydowano się uwzględnić jedynie 29 z 46 cech, co oprócz zmniejszania wymiaru wektora, przyczynia się także do krótszego czasu trenowania i testowania modelu.

## 4) Klasyfikacja

Proces ten przeprowadzono również za pomocą narzędzia WEKA. Uwzględniono 7 różnych klasyfikatorów do rozpoznawania aktywności z nadzorem. Każdy z nich został oceniony, by zobaczyć, który z nich daje najlepszy model. Klasyfikatory zostały użyte w różnych konfiguracjach dając w sumie 10 klasyfikatorów (przedstawiono w tabeli 2).

Tabela 2 Analizowane klasyfikatory

Klasyfikator	Parametr
Maszyna wektorów nośnych	Algorytm SMO
Perceptron wielowarstwowy	17 ukrytych warstw neuronów
Naiwny klasyfikator bayesowski	-
Naiwny klasyfikator bayesowski	BayesNet
Algorytm k-najbliższych sąsiadów	n = 1
Algorytm k-najbliższych sąsiadów	n = 5
Naiwny klasyfikator bayesowski	Metoda bagging
Drzewa decyzyjne	J48

Perceptron wielowarstwowy	25 ukrytych warstw neuronów
kStar	-

Niektóre z najbardziej powszechnych modeli z nadzorem, które często stosuje się w rozpoznawaniu aktywności, to klasyfikatory w oparciu o drzewa decyzyjne (decision tree classifiers), np. J48 i *Random Forest*, maszyny wektorów nośnych (ang. *Support Vector Machines*), K najbliższych sąsiadów (ang. K-nearest neighbours, kNN), naiwne klasyfikatory bayesowskie, regresja logistyczna, perceptron wielowarstwowy, np. sztuczne sieci neuronowe. Niektóre klasyfikatory są bardziej dokładne podczas rozróżniania aktywności, np. modele wielowarstwowych perceptronów są lepsze w przewidywaniu nieco bardziej złożonych aktywności, takich jak joga czy wchodzenie po schodach. Dla prostszych aktywności, takich jak siedzenie czy stanie, drzewa decyzyjne są lepszym rozwiązaniem.

## 6. Sposób zbierania danych przez ochotników

Jeden pomiar polegał na tym, że każda osoba zbierała dane przez 36 sekund dla każdej aktywności bez żadnej przerwy. Z czego 36-sekundowy zapis aktywności skracano do 30 sekund, by pominąć moment zmiany aktywności. W sumie zarejestrowano 5-godzinny zbiór sygnałów, które dawały wartościową informację. Było to jednoznaczne z 505-ma różnymi zapisami aktywności, ilością próbek równą 187 920. Z tego 3.65 godziny zapisu przeznaczono na trenowanie modelu, a 1.57 godziny na testowanie.

## 7. Wyniki

Najlepszymi klasyfikatorami okazały się klasyfikatory kNN i kStar (99,01-procentowa skuteczność). Najgorszym klasyfikatorem był naiwny klasyfikator bayesowski (99,1%). Przeprowadzono także analizę, jak każdy klasyfikator wypadł w zależności od danej aktywności. Na cele porównania klasyfikatorów wykonano macierze niepewności, które pokazywały jak dobrze klasyfikator przewidział aktywność dla każdej aktywności zbioru testowego.

## 8. Uwagi autorów

Dane były testowane *offline*. By otrzymać większą dokładność i mniejsze obciążenie modelu, według autorów, należałoby zebrać dane od więcej niż 10 osób.