

Streszczenie

A Study on Human Activity Recognition Using Accelerometer Data from Smartphones - Akram Bayat, Marc Pomplun, Duc A. Tran

1 Wstęp

W pracy opisanej w tym dokumencie zaproponowane zostało podejście do rozpoznawania aktywności użytkownika na podstawie danych otrzymywanych z akcelerometru wbudowanego w telefon komórkowy.

Do rozpoznawania aktywności na podstawie uzyskanych danych wykorzystano nadzorowane uczenie maszynowe.

Zbudowany przez autorów pracy model służy do rozpoznawania następujących aktywności:

- powolny chód,
- szybki chód,
- bieg,
- wchodzenie po schodach,
- zchodzenie ze schodów

Dane zostały zebrane w postaci wartości x , y , z zwracanych przez akcelerometr. Zebrane dane pochodziły od dwu kobiet oraz mężczyzn, którzy kolejno wykonywali wymienione aktywności. Czas wykonywania aktywności wahał się od 180 do 280 sekund. Dane były zbierane z częstotliwością 100Hz.

2 Ekstrakcja cech

Rozpoznawanie aktywności nie przebiega na surowych danych, lecz na wektorach cech. Dla serii danych A_x , A_y , A_z wykorzystano filtr dolnoprzepustowy, aby oddzielić składowe o wysokiej częstotliwości (AC) od niskiej (DC) powiązanych kolejno z aktywnością użytkownika oraz przyspieszeniem ziemskim. Dokument dokładniej opisuje budowę tego filtra.

Zastosowanie filtra spowodowało dodanie kolejnych 6 serii danych A_{DCi} , A_{ACi} . Do serii danych dodano również wartość A_m , która odpowiada długości wektora $[x, y, z]$.

Z utworzonych 24 cech (dokładny opis w dokumencie strona 5) wybrano 18:

- średnia wartość na osi z ,
- MinMax, odchylenie standardowe, średnia kwadratowa dla A_m ,
- APF - średnie liczba szczytów w oknie osie x, y, z ,

- wariancja APF dla osi x,y,z,
- odchylenie standardowe dla osi x,y,z,
- korelacja pomiędzy osiami z oraz y,
- MinMax dla osi x,y,z

MinMax to różnica pomiędzy maksymalną, a minimalną wartością sygnału występującymi w oknie.

3 Klasyfikatory

W opisywanej tutaj pracy przebadano dokładność następujących klasyfikatorów:

- Multilayer Perceptron
- SVM
- Random Forest
- LMT
- Simple Logistic
- Logit Boost

Przeprowadzono analizę dokładności wykrywania aktywności dla telefonu umieszczonego w kieszeni oraz trzymanego w ręce. Podczas gdy telefon był umieszczony w kieszeni uzyskano dokładność 90.34%. Szczegółowe wyniki przedstawione są na stronie 6.